

PROCESAMIENTO DE IMÁGENES BIOMÉDICAS

INSTITUTO TECNOLÓGICO DE BUENOS AIRES

TP Final

Profesores: Federico MILANO

Matías Alberto ALONSO

Karina GLASER

Fecha: 29/06/2018

Alumno:

Agustina ALTAMIRANO

Franco CHIESA DOCAMPO

Ezequiel FERNÁNDEZ

Pablo PETERS DESTERACT

1 Introducción

Este trabajo consiste en implementar el procesamiento de distintos sets de tomografías computadas, correspondientes a distintos casos, para realizar una segmentación automatizada (y generalizada) de la vía aérea de cada paciente.

El conocimiento detallado de la anatomía segmentaria bronquial es indispensable para entender los patrones de las enfermedades pulmonares y su distribución. Conocer los lóbulos y segmentos es importante tanto para la evaluación topográfica como para la orientación en broncoscopía, planificación de cirugía y radioterapia y como guía en el drenaje postural de neumonías y abscesos.

Para este fin, se buscó implementar el algoritmo de Region Growing, combinado con cálculos adaptativos de los umbrales de trabajo para aumentar la precisión y reducir las probabilidades de ocurrencia de los fenómenos de subsegmentado o sobsegmentado (también conocido como explosión).

2 Método

2.1 Algoritmo: Parte I

Los archivos a segmentar consisten en múltiples cortes axiales, y debido a la alta densidad de datos, junto con el costo computacional (y el tiempo de cómputo) que implicó realizar el análisis en dos dimensiones, se decidió finalmente implementar el algoritmo de Region Growing en 3D. Esto presentó sin embargo varios desafíos, tales como la posición del primer seedpoint (se optó por una implementación semi automática, permitiendo que el usuario elija con precisión el primer seedpoint), o el cálculo adaptativo de umbrales necesario para la segmentación.

En una primer instancia, se intentó implementar la misma idea pero en dos dimensiones. Sin embargo, para ésto, debía aplicarse a cada uno de los cortes una primera etapa de morfología matemática seguido de una corrida del algoritmo utilizado, que en ciertos casos resultaba insuficiente para que el resultado obtenido fuese considerado como aceptable. Para solucionar dichos escapes del algoritmo, se había decidido realizar otra etapa de morfología previa a una nueva pasada de Region Growing lo cual aumentaba el tiempo de espera en sets de imágenes donde la calidad de la misma no era la óptima.

Al mismo momento que se estaba implementando esta opción, por otra parte, se decidió comenzar con la implementación de un camino alternativo basado en el pseudocódigo propuesto por Tsui Ying Law y Pheng Ann Heng, del Departamento de Ingeniería y Ciencias Computacionales de la Universidad de Hong Kong, China. En este caso, no se logró llegar al resultado esperado debido a que el cálculo de umbrales hacía que el algoritmo se volviera altamente costoso desde el punto de vista computacional ya que implicaba calcular varios umbrales, graficando los mismos vs los pixels que se agregaban a la segmentación con dicho umbral. En el gráfico mencionado, encontramos un punto de pendiente máxima por lo que el umbral anterior a dicho punto sería el indicado para la segmentación.

Respecto a los umbrales, se concluyó que debían ser adaptativos debido a que las intensidades a lo largo de la tráquea van variando considerablemente a medida que se llega a lugares más profundos. Para éste punto se probaron distintas técnicas, que fueron desde funciones propuestas por Matlab, la variación a lo largo de distintos umbrales hasta encontrar el ideal como se mencionó en el párrafo anterior y un umbral basado en los dos picos con mayor concentración de counts del histograma de la imagen analizada, entre otras.

Sin embargo, de todas las posibilidades analizadas, la definitiva fue una encontrada en un paper de Imocha Singh *et. al.*, que consta en setear el umbral según la siguiente fórmula:

$$T = k[Median + (Max - Min)(1 - Pixel)] \quad (1)$$

Donde k será una constante a determinar de forma empíricamente, Median la mediana del entorno, Max y Min el máximo y mínimo locales mientras que Pixel será el pixel en cuestión.

Dado que el algoritmo es semi-automático, la elección del primer seedpoint queda a cargo del usuario. Para hacer que la elección pueda hacerse fácilmente, sin necesidad que el usuario tenga grandes conocimientos sobre la disposición de las vías aéreas, se decidió dar como imagen de selección de seedpoint, a la que se encuentra a $\frac{5}{6}$ del total de slices presentes en el caso, ya que estadísticamente se pudo determinar que en la mayoría de los casos, había una buena visualización de la tráquea, limitando el error que pueda cometer el usuario.

2.2 Algoritmo: Parte II

Para la segunda etapa del trabajo lo que se buscó fue medir el diámetro de las vías aéreas del Gold Standard y de la máscara de segmentación obtenida en la parte I del algoritmo. Para comenzar, se realizó una dilatación (imdilate) para rellenar cualquier hueco que pudiera haber quedado por una segmentación imperfecta. Sustrayendo la imagen original a la imagen dilatada se obtiene el contorno de la segmentación.

Por otro lado, se aplicó un algoritmo de esqueletización 3D (Skeleton3D), resultante de una optimización de la implementación en Matlab de [1]. En la figura se observa la superposición de la esqueletización con la máscara del caso 1.



Figure 1: Visualización de la esqueletización de la segmentación y la máscara del caso 1.




Figure 2: Visualización de la esqueletización de la segmentación y los segmentos de los radios generados para el caso 1.




Figure 3: Visualización de los radios y el esqueleto con el contorno.

Se calculó la mínima distancia (euclidiana) desde un punto de la esqueletización a cualquier valor no nulo del contorno, evitando así medir valores superiores a los reales a causa de la inclinación de las ramas al subdividirse. Dado que el esqueleto se encuentra en el centro de la vía, la mínima distancia calculada representa el radio de la misma por lo que se multiplicó por dos para calcular el diámetro. Los puntos elegidos de la esqueletización como muestras para realizar la medición se tomaron con un paso de 1 cada 10 elementos.

3 Resultados

Para poder hacer un análisis sobre los resultados obtenidos, se superpuso la salida del algoritmo con la máscara del caso en cuestión. A su vez, se calcularon distintas métricas para poder determinar la confiabilidad del algoritmo implementado. A continuación se muestran los resultados obtenidos a partir del mismo:




Figure 4: Superposición de la máscara y de la segmentación para el caso 14.




Figure 5: Superposición de la máscara y de la segmentación para el caso 5.

A continuación se presentan los resultados de 23 casos:

Caso	Sensibilidad (%)	Especificidad (%)	Exactitud (%)	Dice (%)	Jaccard (%)	Distancia de Jaccard (%)
1	52,48	99,97	99,92	59,54	42,39	57,61
3	45,85	99,98	99,86	58,75	41,59	58,41
5	44,59	100,00	99,94	61,68	44,59	55,41
6	53,31	99,98	99,91	62,63	45,59	54,41
8	49,55	99,98	99,86	62,02	44,95	55,05
9	33,48	99,97	99,86	45,08	29,10	70,90
14	75,73	100,00	99,98	85,90	75,29	24,71
17	77,27	99,93	99,92	50,09	33,41	66,59
18	77,06	99,95	99,92	69,43	53,17	46,83
20	55,80	99,83	99,78	38,58	23,90	76,10
61	78,65	99,86	99,84	43,11	27,48	72,52
64	96,12	99,94	99,94	65,28	48,45	51,55
66	79,20	99,96	99,93	79,16	65,51	34,49
67	89,47	99,85	99,84	43,21	27,56	72,44
73	75,35	99,97	99,92	78,80	65,02	34,99
75	87,67	99,94	99,93	74,12	58,88	41,12
77	82,32	99,94	99,92	70,69	54,67	45,33
78	81,87	99,88	99,89	53,46	36,48	63,52
81	88,77	99,94	99,94	74,33	59,15	40,85
82	84,62	99,85	99,84	40,74	25,58	74,42
85	85,00	99,96	99,94	79,80	66,39	33,61
87	29,74	99,87	99,79	24,69	14,09	85,91
90	81,78	99,87	99,85	49,52	32,91	67,09
media	69,81	99,93	99,89	59,59	44,18	55,82
desv est	19,43	0,05	0,05	15,88	16,18	16,18

Figure 6: Resultados de 23 casos.




Figure 7: Gráfico de línea de los 23 casos.

Respecto a la segunda parte del trabajo, el diámetro promedio de la tráquea luego de medir da 15.9 mm. En las mediciones se tomaron en cuenta ramas de todos los tamaños, hasta 1 mm o levemente menor.

4 Conclusiones

Los resultados que expusieron nuestros pares, ayudaron al grupo a corregir los puntos débiles del algoritmo, siendo el principal de ellos el tiempo de cómputo. Este último se logró reducir significativamente al tratar el problema con un enfoque en 3 dimensiones. Además, dicha solución, hizo que no fuese necesario aplicar morfología matemática y separación y cálculo de seedpoints que aumentaban el costo/tiempo de cómputo.

En cuanto a los resultados obtenidos, se debe concluir que una de las principales fallas podría deberse a la falta de generalidad de la fórmula utilizada para generar los umbrales adaptativos. Por ende, como trabajo a futuro, se podría combinar este algoritmo junto con la implementación de una función que compare las derivadas de las curvas voxels vs thresholds, para evitar las explosiones al final de la ramas, compensando la ineficiencia del método utilizado.

4.1 Referencias

1. Ta-Chih Lee, Rangasami L. Kashyap and Chong-Nam Chu "Building skeleton models via 3-D medial surface/axis thinning algorithms." Computer Vision, Graphics, and Image Processing, 56(6):462–478, 1994.
2. O. Imocha Singh, *et.al.* "Local Contrast and Mean based Thresholding Technique". International Journal of Computer Applications (0975 – 8887), Volume 51– No.6, August 2012.
3. Segmentation and Analysis of the Human Airway Tree From Three-Dimensional X-Ray CT Images Deniz Aykac, Eric A. Hoffman, Member, IEEE, Geoffrey McLennan, and Joseph M. Reinhardt*, Senior Member, IEEE.